

Московский государственный технический университет
имени Н.Э. Баумана

М.А. Басараб, Н.С. Коннова

**Интеллектуальные технологии
на основе искусственных нейронных сетей**

*Методические указания
к выполнению лабораторных работ*



Москва
ИЗДАТЕЛЬСТВО
МГТУ им. Н. Э. Баумана
2017

УДК 004.8:004.93

ББК 32.813

Б27

Издание доступно в электронном виде на портале *ebooks.bmstu.ru*
по адресу: <http://ebooks.bmstu.ru/catalog/117/book1679.html>

Факультет «Информатика и системы управления»
Кафедра «Информационная безопасность»

*Рекомендовано Редакционно-издательским советом
МГТУ им. Н.Э. Баумана в качестве учебно-методического пособия*

Рецензент

заведующий кафедрой «Информационная безопасность» МТУСИ
д-р техн. наук, профессор *О.И. Шелухин*

Басараб, М. А.

Б27 Интеллектуальные технологии на основе искусственных нейронных сетей. Методические указания к выполнению лабораторных работ / М. А. Басараб, Н. С. Коннова. — Москва : Издательство МГТУ им. Н. Э. Баумана, 2017. — 53, [3] с. : ил.

ISBN 978-5-7038-4716-9

Рассмотрены различные разделы теории искусственных нейронных сетей на примерах решения задач классификации, кластеризации, прогноза, аппроксимации. Исследованы такие типы сетей, как персептрон с правилом обучения Видроу — Хоффа, многослойные с обратным распространением ошибки, сети с радиальными базисными функциями, Хопфилда, двунаправленной ассоциативной памяти (Коско, ВАМ), Кохонена.

Для студентов МГТУ им. Н.Э. Баумана, обучающихся по специальностям «Информационная безопасность» и «Информационная безопасность автоматизированных систем», а также для студентов и аспирантов других специальностей, интересующихся современными методами искусственного интеллекта на основе искусственных нейронных сетей.

УДК 004.8:004.93

ББК 32.813

© МГТУ им. Н.Э. Баумана, 2017

© Оформление. Издательство
МГТУ им. Н.Э. Баумана, 2017

ISBN 978-5-7038-4716-9

Предисловие

Во многих современных задачах по информационной безопасности часто приходится иметь дело с необходимостью осуществления автоматизированной поддержки принятия решений или реализации полностью автоматических экспертных оценок. Одним из наиболее эффективных и универсальных подходов здесь является так называемый метод машинного обучения, теоретическая база которого опирается на аппарат искусственных нейронных сетей (ИНС).

В силу значительного многообразия проблем информационной безопасности с середины XX в. было предложено довольно большое число различных ИНС и их модификаций. В настоящее время направление ИНС непрерывно развивается как в области теории и создания новых типов сетей, так и в плане совершенствования инструментария их реализации (программного и аппаратного). Расширяется и диапазон задач, решаемых методами машинного обучения на основе ИНС.

С точки зрения информационной безопасности ИНС хорошо зарекомендовали себя в задачах выявления аномалий и атак в компьютерных сетях, распознавания биометрических образов (в частности, на нейросетевой парадигме базируется техника сверхвысоко-надежной биометрической аутентификации (СВБА), создаваемая по ГОСТам серии Р 52633), выявления спама, нейрокриптографии и многих других.

В методических указаниях к лабораторным работам предложено практическое ознакомление с самыми известными типами ИНС на примерах ряда более простых математических задач моделирования булевых выражений (однослойный персепtron, сеть RBF), аппроксимации (однослойный персепtron, сеть RBF) и экстраполяции (прогнозирования) функций (сеть авторегрессии), распознавания образов (рекуррентные сети ассоциативной памяти Хопфилда и Кохонена), кластеризации (сеть Кохонена). Решать поставленные

задачи необходимо в два этапа: обучение («с учителем» или ассоциативное) нейронной сети (НС) и непосредственно ее функционирование (рабочий режим).

При выполнении лабораторных работ целесообразно воспользоваться либо готовыми программными пакетами математического моделирования MATLAB (за исключением расширения Neural Networks Toolbox), MathCAD и др., электронными таблицами (MS Excel), либо собственными программами, написанными на языке программирования высокого уровня (C++, C#, Python и др.). В последнем случае программа может реализовать не полное решение задачи, а какие-либо вспомогательные и наиболее рутинные шаги всей процедуры.

При подготовке отчета по каждой лабораторной работе нужно последовательно и подробно представить все основные шаги метода (алгоритма) с выводом промежуточных результатов и необходимыми комментариями, демонстрирующими понимание сути процедуры. Студент должен быть знаком с такими понятиями, как вычислительная сложность и погрешность метода, уметь провести качественный и количественный анализ получаемых результатов, быть способным лаконично ответить на предложенные ему контрольные вопросы.

В методических указаниях содержится достаточный теоретический материал для выполнения каждой лабораторной работы. Вместе с тем для более глубокого понимания нейросетевых моделей и алгоритмов следует использовать дополнительные источники, в том числе указанные в списке литературы.

Данные лабораторные работы предусмотрены учебной программой дисциплин «Интеллектуальные технологии информационной безопасности» и «Интеллектуальные системы информационной безопасности», разработанной на основе практических и лабораторных занятий, которые проводились с 2006 г. на кафедрах «Информационная безопасность» и «Теоретическая информатика и компьютерные технологии» МГТУ им. Н.Э. Баумана. Издание предназначено для студентов МГТУ им. Н.Э. Баумана, обучающихся по специальностям «Информационная безопасность» (100401 — магистратура, 2 курс), «Информационная безопасность автоматизированных систем» (090303 — специалитет, 3 курс), изучающих предмет «Интеллектуальные технологии информационной безопасности».

В результате изучения дисциплины и выполнения лабораторных работ студенты будут знать:

- основные понятия и концепции ИНС;
- типы архитектуры и принципы функционирования ИНС;
- методы обучения ИНС;
- особенности и достоинства вычислительных систем, основанных на нейросетевых технологиях;

уметь:

- выбирать подходящий тип ИНС, исходя из условий поставленной задачи;
- проектировать архитектуру и выбирать количество элементов ИНС в соответствии с требованиями поставленной задачи;
- осуществлять программную реализацию различных моделей ИНС;
- подготавливать данные для обучения ИНС (обучающую выборку) и ее тестирования (тестовую выборку);
- выполнять процесс обучения ИНС;
- осуществлять анализ полученных результатов.

Авторы выражают благодарность аспиранту кафедры «Информационная безопасность» Д.А. Микому за участие в практической аprobации ряда работ.

Лабораторная работа № 1

Исследование однослойных нейронных сетей на примере моделирования булевых выражений

Цель работы — исследовать функционирование простейшей нейронной сети (НС) на базе нейрона с нелинейной функцией активации и обучить ее по правилу Видроу — Хоффа.

Теоретическая часть

Постановка задачи. Получить модель булевой функции (БФ) на основе однослойной НС (единичный нейрон) с двоичными входами $x_1, x_2, x_3, x_4 \in \{0, 1\}$, единичным входом смещения $x_0 = 1$, синаптическими весами w_0, w_1, w_2, w_3, w_4 , двоичным выходом $y \in \{0, 1\}$ и заданной нелинейной функцией активации (ФА) $f: R \rightarrow (0, 1)$ (рис. 1.1).

Для заданной БФ (варианты см. в табл. 1.4) реализовать обучение НС с использованием:

- 1) всех комбинаций переменных x_1, x_2, x_3, x_4 ;
- 2) части возможных комбинаций переменных x_1, x_2, x_3, x_4 ; остальные комбинации являются тестовыми.

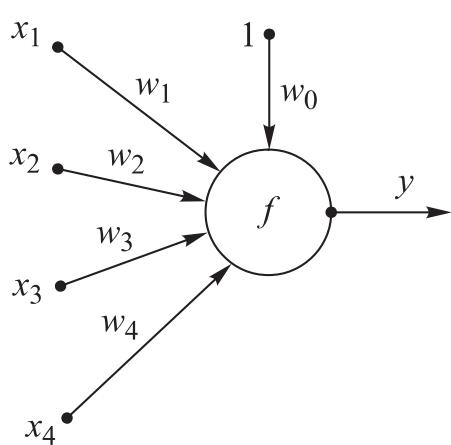


Рис. 1.1. Однослойная НС

Рабочий режим НС. Алгоритм функционирования НС с пороговой ФА имеет вид

$$\begin{aligned} \text{net} &= \sum_{i=1}^4 w_i x_i + w_0; \\ y(\text{net}) &= \begin{cases} 1, & \text{net} \geq 0, \\ 0, & \text{net} < 0, \end{cases} \end{aligned} \quad (1.1)$$

где net — сетевой (комбинированный) вход; y — реальный выход НС.

Алгоритм функционирования НС с логистической ФА выглядит следующим образом:

$$\begin{aligned} \text{net} &= \sum_{i=1}^4 w_i x_i + w_0; \\ \text{out} &= f(\text{net}), \\ y(\text{out}) &= \begin{cases} 1, & \text{out} \geq 0,5, \\ 0, & \text{out} < 0,5, \end{cases} \end{aligned} \quad (1.2)$$

где out — сетевой (недискретизированный) выход НС.

Режим обучения НС. Для необученной НС ее реальный выход y в общем случае отличается от целевого выхода t , представляющего собой значения заданной БФ нескольких переменных $F(x_1, x_2, x_3, x_4): \{0, 1\}^4 \rightarrow \{0, 1\}$, т. е. имеется хотя бы один набор сигналов (x_1, x_2, x_3, x_4) , для которого ошибка

$$\delta = t - y \neq 0. \quad (1.3)$$

Каждая эпоха обучения $k = 1, 2, \dots$ включает в себя цикл последовательного предъявления всех образцов обучающей выборки на вход НС. Предъявление одного обучающего образца внутри эпохи является элементарным шагом обучения $l = 0, 1, 2, \dots$, во время которого вектор весовых коэффициентов $\mathbf{w} = (w_i)_{i=0, \dots, 4}$ корректируется согласно правилу Видроу — Хоффа (дельта-правило):

$$\begin{aligned} w_i^{(l+1)} &= w_i^{(l)} + \Delta w_i^{(l)}, \\ \Delta w_i^{(l)} &= \eta \delta^{(l)} \frac{df(\text{net})}{d \text{net}} x_i^{(l)}, \end{aligned} \quad (1.4)$$

где $\Delta w_i^{(l)}$ — коррекция веса на l -м шаге; $\eta \in (0, 1]$ — норма обучения; $\delta^{(l)}$ — ошибка (1.3) на l -м шаге; $x_i^{(l)}$ ($i = 0, \dots, 4$) — компоненты обучающего вектора на l -м шаге обучения (при этом $x_0^{(l)} \equiv 1$).

Для наиболее популярных сигмоидальных ФА производная $df(\text{net})/d \text{net}$ легко выражается через значения функции $f(\text{net})$.

В случае НС с пороговой ФА (1.1) коррекцию веса в (1.4) следует брать в виде

$$\Delta w_i^{(k)} = \eta \delta^{(l)} x_i^{(l)}. \quad (1.5)$$

При этом реальный выход совпадает с сетевым: $y = \text{out}$.

На каждой эпохе k суммарная квадратичная ошибка $E(k)$ равна расстоянию Хемминга между векторами целевого и реального выходов (размерности $N = 2^4 = 16$) по всем входным векторам $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4$.

Практическая часть

Пример выполнения работы. Получим нейросетевую модель БФ (табл. 1.1):

$$F(x_1, x_2, x_3, x_4) = \overline{x_1 x_2} x_3 x_4.$$

Таблица 1.1

Таблица истинности БФ

x_1	x_2	x_3	x_4	F
0	0	0	0	0
0	0	0	1	0
0	0	1	0	0
0	0	1	1	1
0	1	0	0	0
0	1	0	1	0
0	1	1	0	0
0	1	1	1	1
1	0	0	0	0
1	0	0	1	0
1	0	1	0	0
1	0	1	1	1
1	1	0	0	0
1	1	1	0	0
1	1	1	1	0

На начальном шаге $l = 0$ (эпоха $k = 0$) весовые коэффициенты возьмем в виде

$$w_0^{(0)} = w_1^{(0)} = w_2^{(0)} = w_3^{(0)} = w_4^{(0)} = 0.$$

1. Используем пороговую ФА (1.1). Динамика НС (при норме обучения $\eta = 0,3$) представлена в табл. 1.2. График суммарной ошибки приведен на рис. 1.2.

Таблица 1.2

Параметры НС на последовательных эпохах (пороговая ФА)

Но- мер эпохи k	Вектор весов w	Выходной вектор y	Сум- марная ошиб- ка E
0	(0, 0, 0, 0, 0)	(1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1)	13
1	(-0,6, -0,3, -0,6, 0,3, 0,3)	(0, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0)	2
...
24	(-2,1, -1,2, -0,9, 1,8, 1,5)	(0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0)	0

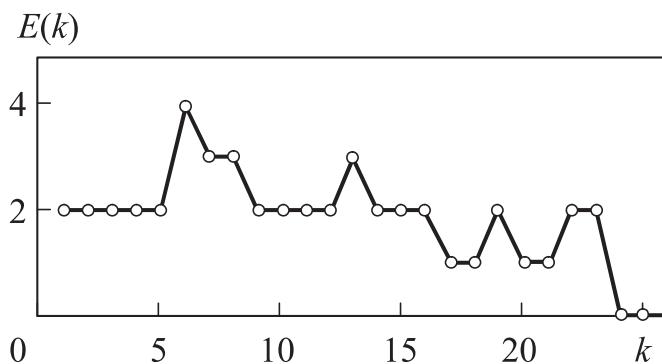


Рис. 1.2. График суммарной ошибки НС по эпохам обучения (пороговая ФА)

2. Используем сигмоидальную (логистическую) ФА:

$$f(\text{net}) = \frac{1}{1 + \exp(-\text{net})},$$

производная которой выражается через значения самой функции как

$$\frac{df(\text{net})}{d\text{net}} = f(\text{net})[1 - f(\text{net})].$$

Для полного обучения (при нулевых начальных весах и норме обучения $\eta = 0,3$) потребовалось 34 эпохи (табл. 1.3). График ошибки приведен на рис. 1.3.

Таблица 1.3

**Параметры НС на последовательных эпохах
(логистическая ФА)**

Номер эпохи k	Вектор весов \mathbf{w}	Выходной вектор \mathbf{y}	Суммарная ошибка E
0	(0, 0, 0, 0, 0)	(1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1)	13
1	(-0,302, -0,170, -0,174, -0,028, -0,033)	(0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, 0)	3
...
34	(-1,811, -0,918, -0,883, 1,379, 1,356)	(0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0, 1, 0, 0, 0)	0

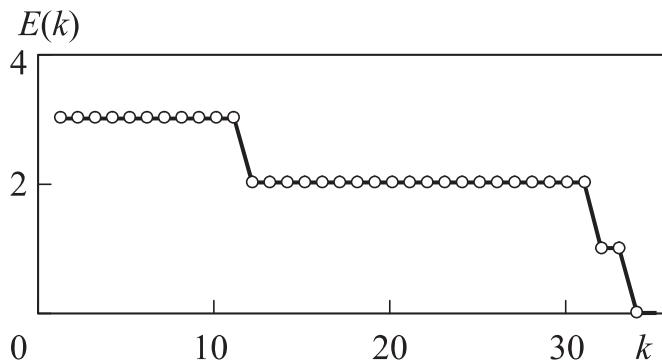


Рис. 1.3. График суммарной ошибки НС по эпохам обучения (логистическая ФА)

3. Рассматривая предыдущий случай, попытаемся последовательно уменьшать размер обучающей выборки, выбирая различные подмножества из 15, 14, 13 и т. д. обучающих векторов до тех пор, пока еще достижима нулевая ошибка. В рассматриваемом примере будет найден минимальный набор из пяти векторов

$$\begin{aligned}\mathbf{x}^{(1)} &= (0, 0, 0, 1), \quad \mathbf{x}^{(2)} = (0, 1, 1, 1), \quad \mathbf{x}^{(3)} = (1, 0, 1, 0), \\ \mathbf{x}^{(4)} &= (1, 0, 1, 1), \quad \mathbf{x}^{(5)} = (1, 1, 1, 0),\end{aligned}$$

дающий следующие синаптические коэффициенты:

$$\mathbf{w} = (-0,225, -0,15, -0,075, 0,15, 0,224).$$

При этом для полного обучения потребовалось лишь 6 эпох.

Варианты заданий

Таблица 1.4

Варианты БФ и ФА

№ варианта	Моделируемая БФ	ФА*
1	$\overline{x_1}x_2(\overline{x_3} + x_4)$	1, 2
2	$(\overline{x_3} + x_4)\overline{x_1} + x_2$	1, 3
3	$x_1 + \overline{x_2} + \overline{(x_3 + x_4)}$	1, 4
4	$(\overline{x_1} + x_3)x_2 + x_2x_4$	1, 2
5	$(\overline{x_1} + x_2 + \overline{x_3})(x_2 + \overline{x_3} + x_4)$	1, 3
6	$x_3x_4 + \overline{x_1} + \overline{x_2}$	1, 4
7	$\overline{(x_1 + x_2)} + x_3 + x_4$	1, 2
8	$(x_1 + x_2 + x_4)x_3$	1, 3
9	$(x_1 + x_2 + x_3)(x_2 + x_3 + x_4)$	1, 4
10	$x_1x_2 + x_3 + x_4$	1, 2
11	$(x_1 + x_2)x_3x_4$	1, 3
12	$(x_1 + x_2)x_3 + x_4$	1, 4
13	$(\overline{x_1} + \overline{x_2} + \overline{x_3})(\overline{x_2} + \overline{x_3} + x_4)$	1, 2
14	$\overline{\overline{(x_1 + x_2)} + x_3 + x_4}$	1, 3
15	$\overline{(x_1 + x_2)x_3 + x_3x_4}$	1, 4
16	$\overline{(x_1 + x_2 + x_3)(x_2 + x_3 + x_4)}$	1, 2
17	$\overline{x_1x_2 + x_3 + x_4}$	1, 3
18	$\overline{(x_1 + x_2)x_3x_4}$	1, 4
19	$\overline{(x_1 + x_2)x_3 + x_4}$	1, 2
20	$\overline{\overline{x_3x_4}}(\overline{x_1} + x_2)$	1, 3
21	$\overline{\overline{(x_1 + x_2)}}\overline{x_3} + x_4$	1, 4

Окончание табл. 1.4

№ варианта	Моделируемая БФ	ФА*
22	$\overline{x_3 + \overline{x_4} + \overline{(x_1 + x_2)}}$	1, 2
23	$\overline{(x_2 + x_4)x_1 + x_1x_3}$	1, 3
24	$\overline{(x_4 + x_3 + \overline{x_2})(x_3 + \overline{x_2} + x_1)}$	1, 4
25	$\overline{x_1x_2 + \overline{x_3} + \overline{x_4}}$	1, 2

* Функции активации:

$$1) f(\text{net}) = \begin{cases} 1, & \text{net} \geq 0, \\ 0, & \text{net} < 0; \end{cases} \quad 3) f(\text{net}) = \frac{1}{1 + \exp(-\text{net})};$$

$$2) f(\text{net}) = \frac{1}{2} \left(\frac{\text{net}}{1 + |\text{net}|} + 1 \right); \quad 4) f(\text{net}) = \frac{1}{2} (\tanh(\text{net}) + 1).$$

Порядок защиты лабораторной работы. Для защиты лабораторной работы студент должен продемонстрировать программную реализацию НС, моделирующей заданную в варианте функцию, результаты обучения сети со всеми промежуточными шагами; предоставить подготовленный отчет согласно указанным ниже требованиям и ответить на контрольные вопросы по теоретической и практической частям работы.

Требования к отчету. В отчете должны содержаться: титульный лист; цель работы; постановка задачи; таблица истинности; график суммарной квадратичной ошибки в зависимости от эпохи обучения; целевые значения и реальный выход НС на каждой эпохе обучения; вектор синаптических коэффициентов на каждой эпохе обучения; минимальный набор обучающих векторов; выводы по результатам численного эксперимента.

Контрольные вопросы

1. Дайте определение персептрана и поясните алгоритм его функционирования.
2. Приведите функции активации НС и их производные.
3. Сформулируйте правило обучения Видроу — Хоффа.

Лабораторная работа № 2

Применение однослойной нейронной сети для решения задач регрессии экспериментальных данных

Цель работы — изучить возможности однослойных НС с правилом обучения Видроу — Хоффа в задачах регрессии экспериментальных данных.

Теоретическая часть

Постановка задачи. В зависимости от варианта работы (табл. 2.1) с помощью НС с линейной функцией активации (рис. 2.1) аппроксимировать функцию $f(x)$ (найти коэффициенты c, d) по набору ее N дискретных значений, заданных равномерно на интервале $[a, b]$ со случайными ошибками $e_i = \text{Arnd}(-0,5; 0,5)$. Выполнить расчет параметров c, d методом наименьших квадратов (МНК) и определить среднеквадратичное отклонение (СКО). Провести обучение НС по правилу Видроу — Хоффа, экспериментальным путем подбрав оптимальный коэффициент обучения η .

Метод наименьших квадратов. Общее выражение для линейной регрессии имеет вид

$$y(x) = cx + d, \quad (2.1)$$

где параметры c, d должны быть выбраны таким образом, чтобы минимизировать сумму квадратов ошибок для всех точек набора экспериментальных данных (x_i, t_i) ($i = 1, N$):

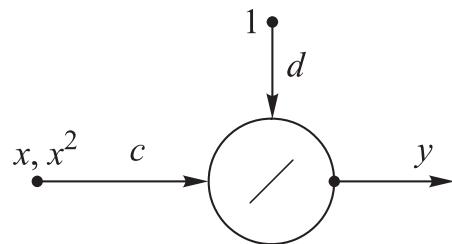


Рис. 2.1. Архитектура НС

$$E^2 = \sum_i [y(x_i) - t_i]^2 \rightarrow \min. \quad (2.2)$$

Подставляя (2.1) в (2.2) и приравнивая частные производные выражения по c, d к нулю, получаем теоретические оценки коэффициентов регрессии:

$$\tilde{c} = \frac{N \sum_i x_i t_i - \sum_i x_i \sum_i t_i}{N \sum_i x_i^2 - \left(\sum_i x_i \right)^2}, \quad \tilde{d} = \frac{\sum_i t_i - \tilde{c} \sum_i x_i}{N}. \quad (2.3)$$

Если гипотеза о линейной зависимости между переменными x, y верна, необязательно ошибка (2.2) будет обращаться в нуль, поскольку в процессе эксперимента реальные данные могут быть получены с погрешностями e_i :

$$t_i = cx_i + d + e_i. \quad (2.4)$$

При необходимости нахождения регрессии другого вида, например

$$y(x) = cx^2 + d, \quad (2.5)$$

можно воспользоваться заменой переменной $z = x^2$ и далее в (2.3) подставить вместо x_i значения $z_i = x_i^2$.

Нейросетевая регрессия. МНК дает уравнение прямой, наилучшим образом аппроксимирующей набор данных. Для нахождения такой прямой можно применить другой подход, основанный на использовании НС с линейной функцией активации (см. рис. 2.1) и обучении, т. е. настройке ее весов c, d по некоторой выборке. Поскольку сеть однослойная, обучение можно реализовать по правилу Видроу — Хоффа.

Алгоритм функционирования НС с линейной ФА имеет вид

$$\text{net} = cx + d; \quad y(\text{net}) = \text{net}, \quad (2.6)$$

где net — сетевой (комбинированный) вход; y — реальный выход НС.

Для необученной НС ее реальный выход $y_i = y(x_i)$ в общем случае отличается от целевого выхода t_i , представляющего собой данные, полученные с погрешностями, т. е. имеется ошибка

$$\delta_i = t_i - y_i \neq 0. \quad (2.7)$$

Каждая эпоха обучения $k = 1, 2, \dots$ включает в себя цикл последовательного предъявления всех образцов обучающей выборки $i = \overline{1, N}$ на вход НС. Предъявление одного обучающего образца внутри эпохи является элементарным шагом обучения, во время которого вектор весовых коэффициентов $\mathbf{w} = (c, d)$ корректируется согласно правилу Видроу — Хоффа:

$$\begin{aligned}\hat{c}^{(i+1)} &= \hat{c}^{(i)} + \Delta\hat{c}^{(i)}, & \Delta\hat{c}^{(i)} &= \eta\delta_i x_i, \\ \hat{d}^{(i+1)} &= \hat{d}^{(i)} + \Delta\hat{d}^{(i)}, & \Delta\hat{d}^{(i)} &= \eta\delta_i,\end{aligned}\tag{2.8}$$

где η — норма обучения, $\eta \in (0, 1]$.

Практическая часть

Пример выполнения работы. Рассмотрим линейную регрессию (2.1) на интервале $a = 0, b = 3$ с известными параметрами

$$c = 0,5, \quad d = 2.$$

Набор данных содержит $N = 32$ отсчета.

При отсутствии шума ($A = 0$) МНК дает точные значения параметров регрессии (2.3):

$$\tilde{c} = c, \quad \tilde{d} = d.$$

В то же время НС, обученная в течение $K = 17$ эпох с параметром $\eta = 0,05$, дает следующие результаты:

$$\hat{c} = 0,503, \quad \hat{d} = 1,991; \quad E^2 = 7,849 \cdot 10^{-4}.$$

При наличии шума ($A = 0,5$) соответствующие результаты для МНК:

$$\tilde{c} = 0,485, \quad \tilde{d} = 2,024; \quad E^2 = 0,584;$$

для НС ($K = 50, \eta = 0,05$):

$$\tilde{c} = 0,496, \quad \tilde{d} = 2,021; \quad E^2 = 0,592.$$

На рис. 2.2 показаны погрешности приближения в условиях шума.

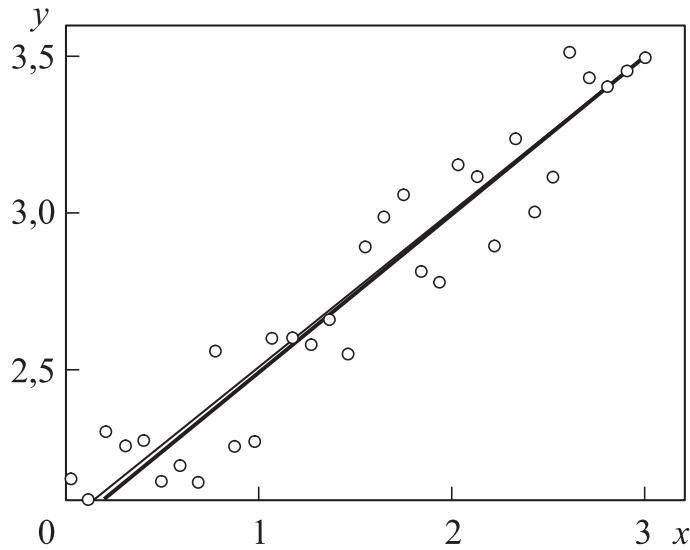


Рис. 2.2. Нейросетевая линейная регрессия экспериментальных данных: полужирная линия — точная зависимость; тонкая линия — нейросетевая регрессия; круглые маркеры — зашумленные отсчеты

Варианты заданий

Таблица 2.1

Исходные данные

№ варианта	$f(x)$	c	d	a	b	N	A
1	$cx + d$	3	1	-2	2	16	2
2	$cx^2 + d$	-4	2	-1	2	12	5
3	$cx + d$	0	3	-4	2	24	0,1
4	$cx^2 + d$	-0,5	0	-2	2	16	2
5	$cx + d$	-500	200	0	10	24	1000
6	$cx^2 + d$	0,5	0	-2	1	20	1
7	$cx + d$	8	0	-4	2	24	10
8	$cx^2 + d$	3	1	-1	3	16	3
9	$cx + d$	-4	2	-3	3	12	6
10	$cx^2 + d$	1	0	-2	2	24	2
11	$cx + d$	-10	0	-5	0	20	10
12	$cx^2 + d$	-1	3	0	3	10	3
13	$cx + d$	1000	0	-5	5	20	2000
14	$cx^2 + d$	-3	1	-3	0	8	3

Окончание табл. 2.1

№ варианта	$f(x)$	c	d	a	b	N	A
15	$cx + d$	0,1	2	-5	0	32	0,2
16	$cx^2 + d$	-5	5	0	4	16	2
17	$cx + d$	-0,5	2	-2	1	20	0,4
18	$cx^2 + d$	-1	3	-1	2	8	1
19	$cx + d$	-3	-2	-2	2	20	3
20	$cx^2 + d$	1	3	-2	2	10	1
21	$cx + d$	-2	4	0	2	20	2
22	$cx^2 + d$	-3	3	-2	2	16	1,5
23	$cx + d$	1	3	1	2	16	0,2
24	$cx^2 + d$	2	2	-1	1	10	0,5
25	$cx + d$	-1	3	-1	2	8	2

Порядок защиты лабораторной работы. Для защиты лабораторной работы студент должен продемонстрировать программную реализацию НС, аппроксимирующей заданную в варианте функцию, результаты обучения сети со всеми промежуточными шагами; предоставить подготовленный отчет согласно указанным ниже требованиям и ответить на контрольные вопросы по теоретической и практической частям работы.

Требования к отчету. В отчете должны содержаться: титульный лист; цель работы; постановка задачи; результаты эксперимента (аппроксимируемая функция $f(x)$, зашумленная функция и их графики; график функции с параметрами, найденными по МНК, СКО; результат обучения — набор вычисленных синаптических весов c и d с волной \tilde{m}, \tilde{c} для функции без шума и с шумом, СКО, графики аппроксимирующей и аппроксимируемой функций); выводы по результатам численного эксперимента.

Контрольные вопросы

1. Объясните понятие регрессии экспериментальных данных.
2. Поясните суть метода наименьших квадратов.
3. Сформулируйте нейросетевой подход к задачам регрессии.

Лабораторная работа № 3

Применение однослойной нейронной сети с линейной функцией активации для прогнозирования временных рядов

Цель работы — изучить возможности однослойных НС в задачах прогнозирования временных рядов методом скользящего окна (авторегрессия).

Теоретическая часть

Постановка задачи. На временном интервале $[a, b]$ задан дискретный набор значений функции $x(t)$ (варианты см. в табл. 3.1). Количество точек $N = 20$, расположение — равномерное. Методом «скользящего окна» спрогнозировать поведение функции $x(t)$ на N точках последующего интервала $(b, 2b - a]$. Для решения использовать однослойную НС с количеством нейронов p и линейной функцией активации. Исходное количество нейронов (длина окна) $p = 4$. Обучение проводить методом Видроу — Хофффа (см. лабораторные работы № 1, 2). Исследовать влияние количества эпох M обучения и коэффициента обучения η на среднеквадратичную погрешность приближения

$$\varepsilon = \sqrt{\sum_i [x(t_i) - \tilde{x}(t_i)]^2}.$$

Исследовать процесс прогнозирования при постепенном изменении (уменьшении/увеличении) размера окна p . Сделать выводы по результатам численного эксперимента.

Метод «скользящего окна». Под временным рядом будем подразумевать функциональную зависимость $x = x(t)$, заданную на дискретном множестве отсчетов (моментов времени)

$$t = t_i \quad (i = \overline{1, m}),$$

так что

$$x_i = x(t_i) \quad (i = \overline{1, m}).$$

Одной из простейших моделей прогноза является авторегрессионная модель, когда прогнозируемое значение ряда в момент времени $n > m$ выражается через его известные значения в предыдущие моменты времени:

$$\tilde{x}_n = \sum_{k=1}^p w_k x_{n-p+k-1}, \quad (3.1)$$

где p — размер «окна» данных, по которому производится прогноз; w_k — некоторые весовые коэффициенты.

Выражение (3.1) часто используется для центрированных временных рядов, среднее значение которых равно 0. Если математическое ожидание временного ряда равно \bar{x} , то вместо (3.1) можно воспользоваться представлением

$$\tilde{x}_n = \sum_{k=1}^p w_k x_{n-p+k-1} + w_0, \quad (3.2)$$

где $w_0 = \bar{x}$.

Ошибка прогноза (локальная) равна апостериорной разнице спрогнозированного и реального значений временного ряда:

$$\delta_n = x_n - \tilde{x}_n. \quad (3.3)$$

НС прогноза. Нахождение неизвестных весовых коэффициентов w_k осуществляется по известной обучающей выборке значений временного ряда $x_i = x(t_i)$ ($i = \overline{1, m}$). Для этого необходимо определить окно длиной $p < m$. Далее, начиная с левого края временного ряда, следует прогнозировать его значения в моменты, идущие непосредственно за окном (справа от него). Сравнивая этот прогноз с реальными значениями, можно оценить ошибку (3.3), а на ее основе — скорректировать весовые коэффициенты w_k , например, с помощью методов обучения НС.

Простейшая архитектура НС показана на рис. 3.1. Функция активации — линейная, т. е.

$$f(\text{net}) = \text{net},$$

где net — комбинированный вход единственного нейрона,

$$\text{net} = \sum_{k=1}^p w_k x_{i+k-1} + w_0.$$

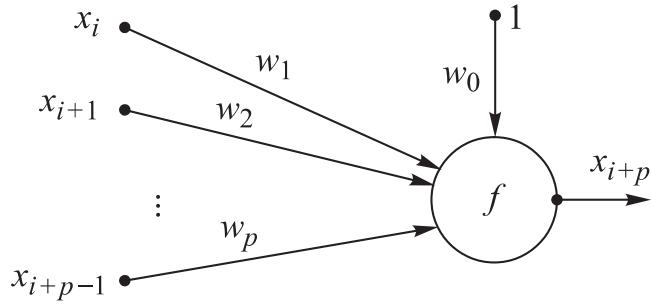


Рис. 3.1. Архитектура нейронной сети

В режиме обучения последовательно, от эпохи к эпохе, на вход сети подаются элементы векторов-столбцов обучающей выборки

$$\mathbf{X} = \begin{pmatrix} x_1 & x_2 & \dots & x_{m-p} \\ x_2 & x_3 & \dots & x_{m-p+1} \\ \vdots & \vdots & \ddots & \vdots \\ x_p & x_{p+1} & \dots & x_{m-1} \end{pmatrix}, \quad (3.4)$$

а на выходе соответственно получаются прогнозируемые значения:

$$\tilde{x}_{p+1}, \tilde{x}_{p+2}, \dots, \tilde{x}_{m-1}.$$

Эти значения сравниваются с реальными

$$x_{p+1}, x_{p+2}, \dots, x_{m-1}$$

и по (3.3) оценивается ошибка. Коррекция весов на каждой эпохе производится по правилу Видроу — Хоффа:

$$\Delta w_k = \eta \delta x_k, \quad k = \overline{0, p},$$

где η — норма обучения, $\eta \in (0, 1]$.

Если по достижении правого края выборки (3.4) суммарная среднеквадратичная ошибка $\varepsilon = \sqrt{\sum_i [x(t_i) - \tilde{x}(t_i)]^2}$ останется достаточно большой, следует продолжить обучение, снова вернувшись к первому столбцу (3.4) и т. д.

В рабочем режиме прогноз осуществляется путем сдвига окна далее вправо на 1, 2, 3 и т. д. отсчета относительно последнего столбца (3.4). При этом, начиная со сдвига на 2, в прогнозе будут принимать значения, в свою очередь спрогнозированные ранее, что может привести к росту ошибки долговременного прогноза.

Практическая часть

Пример выполнения работы. Рассмотрим прогноз функции $X(t) = 0,5 \sin 0,5t - 0,5$ по 20 равноотстоящим исходным значениям x , заданным на интервале $t \in [-2, 4]$ (рис. 3.2). Выберем длину окна $p = 6$, норму обучения $\eta = 1$. Без ограничения общности будем считать вес смещения $w_0 = 0$. На рис. 3.3 показаны график самой функции и ее прогноз (круглые маркеры) на интервале $t \in [4, 10]$ при различном количестве эпох обучения M .

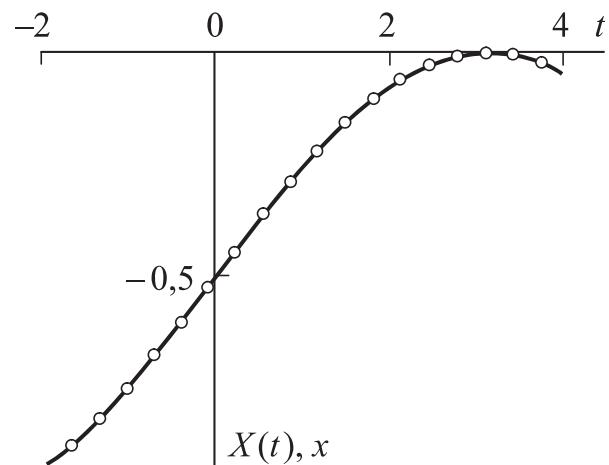


Рис. 3.2. Исходная функция:
— $X(t)$; $\circ \circ \circ$ — x





Рис. 3.3. Исходная функция и ее прогноз при различном количестве эпох обучения:
 a — $M = 2000$ ($\varepsilon \approx 1,515$); β — $M = 4000$ ($\varepsilon \approx 0,040$);
— $X(t)$; $\circ \circ \circ$ — x

Вектор весовых коэффициентов при $M = 4000$ равен

$$\mathbf{w} = (0, 0, 503, -0, 289, -0, 590, -0, 392, 0, 300, 1, 468).$$

Сравнивая результаты прогноза при различном количестве эпох, следует отметить, что его качество неудовлетворительно примерно до $M \approx 3500$, а затем быстро улучшается, и при $M > 4000$ прогнозные значения практически совпадают с точными в пределах графического изображения.

Варианты заданий

Таблица 3.1

Варианты функций

№ варианта	Функция $x(t)$	a	b
1	$0,5 \cos 0,5t - 0,5$	-5	5
2	$t^4 - 2t^3 + t$	-0,5	0,5
3	$\exp(t - 1)$	-2	2
4	$0,5 \exp(0,5 \cos 0,5t) + \sin 0,5t$	-5	3
5	$\sqrt{\operatorname{tg}(-t)}$	1,7	2
6	$\sqrt{0,1t} + 1$	1	5
7	$0,4 \sin 0,3t + 0,5$	-4	4
8	$\sin^2 t$	0	2
9	$\exp(t - 2) - \sin t$	-1	2
10	$\sin(t - 1)$	-2	2
11	$\operatorname{tg} t$	2	3
12	$\exp(-0,1t^2)$	-5	5
13	$\sin(0,1t^3 - 0,2t^2 + t - 1)$	0	1
14	$\sin(2\sqrt{\exp t})$	4,5	5
15	$0,5 \cos 0,5t - \sin t$	0	4
16	$\ln t - 1$	1	5
17	$\cos^2 t - 0,5$	-1	0,5

Окончание табл. 3.1

№ варианта	Функция $x(t)$	a	b
18	$\cos t$	1	1,5
19	t^2	-1	1
20	$t^2 \sin t$	-1	1
21	$0,1 \sin 3t + \cos t$	1	1,5
22	$0,2 \sin 4t$	1,2	1,5
23	$0,1 \cos 3t - 0,5$	-1	0
24	$\operatorname{tg} 3t$	-0,1	0
25	$t^2 \exp t$	-0,1	0,3

Порядок защиты лабораторной работы. Для защиты лабораторной работы студент должен продемонстрировать программную реализацию НС, прогнозирующей заданную в варианте функцию, результаты обучения сети со всеми промежуточными шагами для каждого этапа эксперимента; предоставить подготовленный отчет согласно указанным ниже требованиям и ответить на контрольные вопросы по теоретической и практической частям работы.

Требования к отчету. В отчете должны содержаться: титульный лист; цель работы; постановка задачи; результаты эксперимента (в виде графиков функций, зависимостей погрешности от числа эпох и нормы обучения); выводы по результатам численного эксперимента.

Контрольные вопросы

1. В чем состоит принцип прогнозирования на основе авторегрессии?
2. Объясните методику обучения НС прогноза.
3. Поясните принцип функционирования НС прогноза.

Лабораторная работа № 4

Исследование нейронных сетей с радиальными базисными функциями (RBF) на примере моделирования булевых выражений

Цель работы — исследовать функционирование НС с радиальными базисными функциями (RBF) и обучить ее по правилу Видроу — Хоффа.

Теоретическая часть

Постановка задачи. Получить модель булевой функции (БФ) на основе RBF-НС с двоичными входами $x_1, x_2, x_3, x_4 \in \{0, 1\}$, единичным входом смещения $\varphi_0 = 1$, синаптическими весами v_0, v_1, v_2, v_3, v_4 , двоичным выходом $y \in \{0, 1\}$ с пороговой ФА выходного нейрона, J скрытыми RBF-нейронами с гауссовой ФА $\varphi: R \rightarrow (0, 1]$ и координатами центров $c_{j1}, c_{j2}, c_{j3}, c_{j4}$ ($j = \overline{1, J}$) (рис. 4.1).

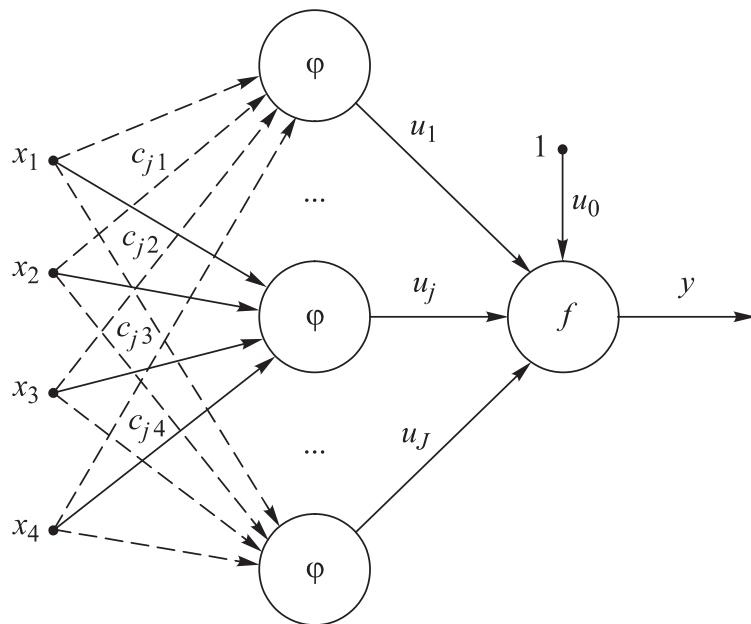


Рис. 4.1. Нейронная сеть RBF

Для заданной БФ (варианты см. в табл. 4.1) количество RBF-нейронов необходимо выбирать из соотношения $J = \min\{J_0, J_1\}$, где J_0, J_1 — количество векторов $\mathbf{x} = (x_1, x_2, x_3, x_4)$, соответствующих значениям БФ «0» и «1». Центры RBF $\mathbf{c}^{(j)} = (c_{j1}, c_{j2}, c_{j3}, c_{j4})$ должны совпадать с концами этих векторов.

Требуется найти минимальный набор векторов \mathbf{x} , используемых для обучения.

Рабочий режим НС. Алгоритм функционирования НС с гауссовой RBF имеет вид

$$\begin{aligned}\varphi_j(X) &= \exp\left(-\sum_{i=1}^4(x_i - c_{ji})^2\right), \quad j = \overline{1, J}; \\ \text{net} &= \sum_{j=1}^J v_j \varphi_j(X) + v_0; \\ y(\text{net}) &= \begin{cases} 1, & \text{net} \geq 0, \\ 0, & \text{net} < 0, \end{cases}\end{aligned}\tag{4.1}$$

где net — сетевой (комбинированный) вход; y — реальный выход НС.

Режим обучения НС. Для необученной НС ее реальный выход y в общем случае отличается от целевого выхода t , представляющего собой значение заданной БФ нескольких переменных $F(x_1, x_2, x_3, x_4): \{0, 1\}^4 \rightarrow \{0, 1\}$, т. е. имеется хотя бы один набор сигналов (x_1, x_2, x_3, x_4) , для которого ошибка

$$\delta = t - y \neq 0.\tag{4.2}$$

Каждая эпоха обучения $k = 1, 2, \dots$ включает в себя цикл последовательного предъявления всех образцов обучающей выборки на вход НС. Предъявление одного обучающего образца внутри эпохи является элементарным шагом обучения $l = 0, 1, 2, \dots$, во время которого вектор весовых коэффициентов $\mathbf{v} = (v_j)_{j=0, \dots, J}$ корректируется согласно правилу Видроу — Хоффа:

$$\begin{aligned}v_j^{(l+1)} &= v_j^{(l)} + \Delta v_j^{(l)}, \\ \Delta v_j^{(l)} &= \eta \delta^{(l)} \varphi_j^{(l)}(X),\end{aligned}\tag{4.3}$$

где $\Delta v_j^{(l)}$ — коррекция веса на l -м шаге; $\eta \in (0, 1]$ — норма обучения; $\delta^{(l)}$ — ошибка (4.2) на l -м шаге обучения; $\varphi_j^{(l)} (j = 0, J)$ — выходы RBF-нейронов на l -м шаге обучения (при этом $\varphi_0^{(l)} \equiv 1$).

На каждой эпохе k суммарная квадратичная ошибка $E(k)$ равна расстоянию Хемминга между векторами целевого и реального выходов (размерности $N = 2^4 = 16$) по всем входным векторам $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4$.

Практическая часть

Пример выполнения работы. Построим RBF-модель для БФ из примера в лабораторной работе № 1 (см. табл. 1.1):

$$F(x_1, x_2, x_3, x_4) = \overline{x_1 x_2} x_3 x_4.$$

На начальном шаге $l = 0$ (эпоха $k = 0$) весовые коэффициенты возьмем в виде

$$v_0^{(0)} = v_1^{(0)} = v_2^{(0)} = v_3^{(0)} = v_4^{(0)} = 0,$$

а норму обучения — $\eta = 0,3$.

Находим количество RBF-нейронов: $J = 3$. Центры RBF-нейронов располагаем в точках

$$C^{(1)} = (0, 0, 1, 1), \quad C^{(2)} = (0, 1, 1, 1), \quad C^{(3)} = (1, 0, 1, 1).$$

В качестве обучающей выборки можно взять минимальный набор из пяти векторов, найденный в лабораторной работе № 1:

$$\begin{aligned} \mathbf{x}^{(1)} &= (0, 0, 0, 1), & \mathbf{x}^{(2)} &= (0, 1, 1, 1), & \mathbf{x}^{(3)} &= (1, 0, 1, 0), \\ \mathbf{x}^{(4)} &= (1, 0, 1, 1), & \mathbf{x}^{(5)} &= (1, 1, 1, 0). \end{aligned}$$

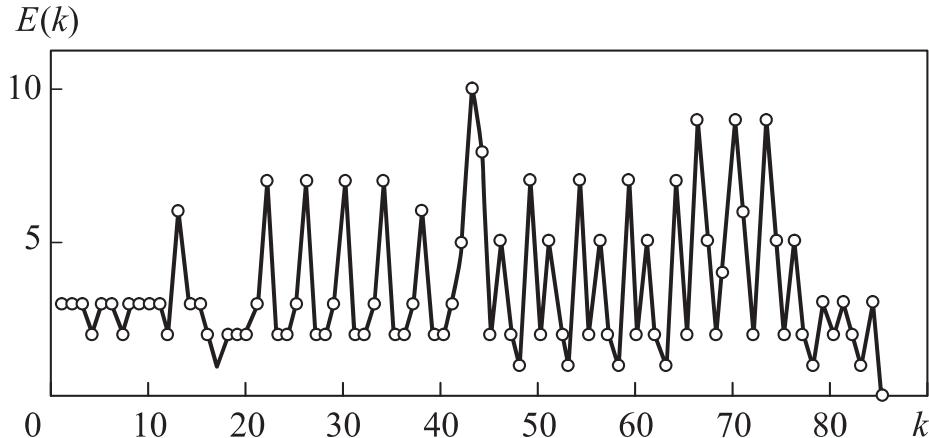


Рис. 4.2. График суммарной ошибки НС по эпохам обучения

В итоге цикл полного обучения занял 85 эпох (рис. 4.2), а коэффициенты синаптических весов имеют вид:

$$\mathbf{v} = (16,5, -2,592, -2,158, -0,506).$$

Варианты заданий

Таблица 4.1

Варианты БФ и ФА

№ варианта	Моделируемая БФ	ФА
1	$\overline{x_1}x_2(\overline{x_3} + x_4)$	1, 2
2	$(\overline{x_3} + x_4)\overline{x_1} + x_2$	1, 3
3	$x_1 + \overline{x_2} + \overline{(x_3 + x_4)}$	1, 4
4	$(\overline{x_1} + x_3)x_2 + x_2x_4$	1, 2
5	$(\overline{x_1} + x_2 + \overline{x_3})(x_2 + \overline{x_3} + x_4)$	1, 3
6	$x_3x_4 + \overline{x_1} + \overline{x_2}$	1, 4
7	$\overline{(x_1 + x_2)} + x_3 + x_4$	1, 2
8	$(x_1 + x_2 + x_4)x_3$	1, 3
9	$(x_1 + x_2 + x_3)(x_2 + x_3 + x_4)$	1, 4
10	$x_1x_2 + x_3 + x_4$	1, 2
11	$(x_1 + x_2)x_3x_4$	1, 3
12	$(x_1 + x_2)x_3 + x_4$	1, 4
13	$(\overline{x_1} + \overline{x_2} + \overline{x_3})(\overline{x_2} + \overline{x_3} + x_4)$	1, 2
14	$\overline{\overline{(x_1 + x_2)} + x_3 + x_4}$	1, 3
15	$\overline{(x_1 + x_2)x_3 + x_3x_4}$	1, 4
16	$\overline{(x_1 + x_2 + x_3)(x_2 + x_3 + x_4)}$	1, 2
17	$\overline{x_1x_2 + x_3 + x_4}$	1, 3
18	$\overline{(x_1 + x_2)x_3x_4}$	1, 4
19	$\overline{\overline{(x_1 + x_2)x_3 + x_4}}$	1, 2

Окончание табл. 4.1

№ варианта	Моделируемая БФ	ФА
20	$\overline{\overline{x_3x_4}}(\overline{\overline{x_1}} + \overline{x_2})$	1, 3
21	$\overline{(x_1 + x_2)}\overline{x_3} + \overline{x_4}$	1, 4
22	$\overline{x_3} + \overline{x_4} + \overline{(x_1 + x_2)}$	1, 2
23	$\overline{(x_2 + x_4)}x_1 + x_1\overline{x_3}$	1, 3
24	$\overline{(x_4 + x_3 + x_2)}(x_3 + \overline{x_2} + x_1)$	1, 4
25	$\overline{x_1}\overline{x_2} + \overline{x_3} + \overline{x_4}$	1, 2

Порядок защиты лабораторной работы. Для защиты лабораторной работы студент должен продемонстрировать программную реализацию НС, моделирующей заданную в варианте функцию, результаты обучения сети со всеми промежуточными шагами; предоставить подготовленный отчет согласно указанным ниже требованиям и ответить на контрольные вопросы по теоретической и практической частям работы.

Требования к отчету. Отчет должен содержать: титульный лист; цель работы; постановку задачи; таблицу истинности; параметры RBF; набор обучающих векторов; график суммарной квадратичной ошибки в зависимости от эпохи обучения; вектор найденных синаптических коэффициентов; выводы по результатам численного эксперимента.

Контрольные вопросы

1. Расскажите о НС RBF и алгоритме ее функционирования.
2. Назовите типы радиальных базисных функций.
3. Как происходят нахождение параметров и обучение НС RBF?

Лабораторная работа № 5

Исследование аппроксимативных свойств нейронных сетей с радиальными базисными функциями (RBF)

Цель работы — исследовать аппроксимацию одномерной функции с помощью НС с радиальными базисными функциями (RBF).

Теоретическая часть

Постановка задачи. Аппроксимировать функцию $F(t)$ на интервале $[a, b]$ (варианты см. в табл. 3.1) с помощью сети с *гауссовыми RBF*:

$$\varphi(t) = \exp\left(-\frac{1}{2\sigma^2}(c - t)^2\right). \quad (5.1)$$

Архитектура сети (рис. 5.1): один входной нейрон; J нейронов слоя RBF (центры $c_j = a + j(b - a)/(J + 1)$, $j = \overline{1, J}$); один выходной нейрон (линейная функция активации). Размер обучающей

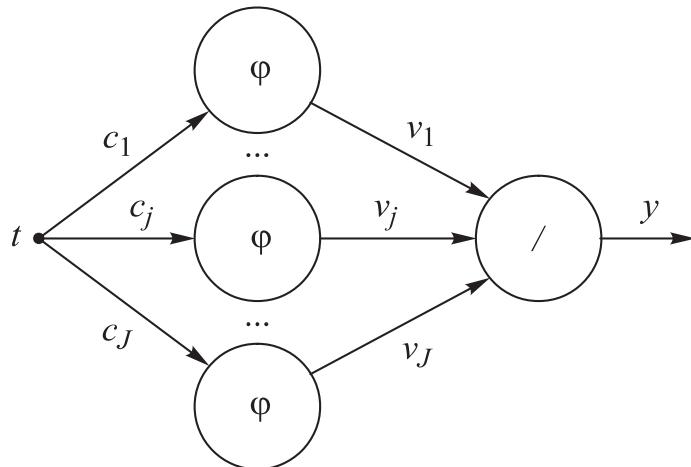


Рис. 5.1. Архитектура нейронной сети RBF

выборки Q . Весовые коэффициенты v_j определить по правилу Видроу — Хоффа. Исследовать влияние ширины RBF σ и коэффициента обучения $\eta \in (0, 1]$ на погрешность приближения $E = \sqrt{\sum_i (f(t_i) - y_i)^2}$, $i = \overline{1, N}$ ($N = J$) при количестве эпох обучения $K = 1$.

Рабочий режим НС. Алгоритм функционирования НС с RBF (5.1) имеет вид

$$\begin{aligned} \varphi_j(t) &= \exp\left(-\frac{1}{2\sigma^2}(c_j - t)^2\right), \quad j = \overline{1, J}; \\ \text{net}(t) &= \sum_{j=1}^J v_j \varphi_j(t); \quad y(\text{net}) = \text{net}, \end{aligned} \quad (5.2)$$

где net — сетевой (комбинированный) вход; y — реальный выход НС.

Режим обучения НС. Для необученной НС ее реальный выход y в общем случае отличается от целевого выхода, представляющего собой значения заданной функции $f(t)$, т. е. имеется ошибка

$$\delta(t) = f(t) - y \neq 0. \quad (5.3)$$

Каждая эпоха обучения $k = 1, 2, \dots$ включает в себя цикл последовательного предъявления образцов обучающей выборки на вход НС. Предъявление одного обучающего образца t_i ($i = \overline{1, N}$) внутри эпохи является элементарным шагом обучения $l = 1, 2, 3, \dots$, во время которого вектор весовых коэффициентов $\mathbf{v} = (v_j)_{j=\overline{1, J}}$ корректируется согласно правилу Видроу — Хоффа:

$$\begin{aligned} v_j^{(l+1)} &= v_j^{(l)} + \Delta v_j^{(l)}, \\ \Delta v_j^{(l)} &= \eta \delta^{(l)} \varphi_j^{(l)}, \end{aligned}$$

где $\Delta v_j^{(l)}$ — коррекция веса на l -м шаге обучения; $\eta \in (0, 1]$ — норма обучения; $\delta^{(l)}$ — ошибка (5.3) на l -м шаге; $\varphi_j^{(l)}$ ($j = \overline{1, J}$) — выходы RBF-нейронов на l -м шаге обучения.

Практическая часть

Пример выполнения работы. Произведем аппроксимацию функции

$$\exp(t-2) + \cos 2t,$$

заданной на интервале с концами $a = -1$, $b = 2$.




Рис. 5.2. Аппроксимация функции сетью RBF

Размер обучающей выборки $Q = 20$. Аппроксимация выполняется с помощью $J = 9$ нейронов RBF. На рис. 5.2 показаны графики исходной функции (полужирная линия), точек обучающей выборки (круглые маркеры) и аппроксимирующей кривой (5.2) с параметрами $\eta = 0,2$, $\sigma = 0,5$. Количество эпох обучения $K = 50$, результирующая среднеквадратичная ошибка $E \approx 0,456$. Вектор весовых коэффициентов:

$$\mathbf{v} = (-1,326; 0,224; 1,201; 1,150; 0,278; -0,694; -0,993; -0,312; 0,987).$$

Варианты заданий

Варианты заданий представлены в табл. 3.1.

Порядок защиты лабораторной работы. Для защиты лабораторной работы студент должен продемонстрировать программную реализацию НС, аппроксимирующую заданную в варианте функцию, результаты обучения сети со всеми промежуточными

шагами; предоставить подготовленный отчет согласно указанным ниже требованиям и ответить на контрольные вопросы по теоретической и практической частям работы.

Требования к отчету. В отчете должны содержаться: титульный лист; цель работы; постановка задачи; результаты эксперимента (в виде графиков функций, зависимостей погрешности от числа эпох и нормы обучения); вектор найденных синаптических коэффициентов; выводы по результатам численного эксперимента.

Контрольные вопросы

1. Расскажите о НС RBF и алгоритме ее функционирования.
2. Назовите типы радиальных базисных функций.
3. Как происходит нахождение параметров и обучение НС RBF?

Лабораторная работа № 6

Изучение алгоритма обратного распространения ошибки (метод Back Propagation)

Цель работы — исследовать функционирование многослойной нейронной сети (МНС) прямого распространения и ее обучение методом обратного распространения ошибки (англ. Back Propagation — BP).

Теоретическая часть

Постановка задачи. На примере МНС архитектуры $N - J - M$ (рис. 6.1) реализовать ее обучение методом BP, проведя настройку весов нейронов скрытого ($w_{ij}^{(1)}(k)$, $i = \overline{0, N}$, $j = \overline{1, J}$) и выходного ($w_{jm}^{(2)}(k)$, $j = \overline{0, J}$, $m = \overline{1, M}$) слоев, где индексы $i, j = 0$ соответствуют нейронам смещения; $k = 1, 2, \dots$ — номер эпохи обучения.

Алгоритм обратного распространения ошибки. Обозначения:

$x_i^{(1)}, x_j^{(2)}(k)$ — входные сигналы нейронов скрытого и выходного слоев;

$\text{net}_j^{(1)}(k), \text{net}_m^{(2)}(k)$ — комбинированные входы нейронов скрытого и выходного слоев;

$\text{out}_j^{(1)}(k), \text{out}_m^{(2)}(k)$ — выходные сигналы нейронов скрытого и выходного слоев;

$\delta_j^{(1)}(k), \delta_m^{(2)}(k)$ — ошибки скрытого и выходного слоев.

Начальные веса $w_{ij}^{(1)}(0), w_{jm}^{(2)}(0)$ принять произвольными.




Рис. 6.1. Многослойная НС

Функция активации нейронов скрытого и выходного слоев

$$f(\text{net}) = \frac{1 - \exp(-\text{net})}{1 + \exp(-\text{net})} \in (-1, 1).$$

Ее производная выражается через значения самой функции как

$$\frac{df(\text{net})}{d \text{net}} = \frac{1}{2} [1 - f^2(\text{net})].$$

На *первом этапе* следует рассчитать по заданному входному сигналу x_i , $i = \overline{0, N}$ выход МНС $y_m(k)$:

$$1) x_i^{(1)} \equiv x_i, \quad i = \overline{0, N};$$

$$2) \text{net}_j^{(1)}(k) = \sum_{i=1}^N w_{ij}^{(1)}(k)x_i^{(1)} + w_{0j}^{(1)}(k), \quad j = \overline{1, J};$$

$$3) x_j^{(2)}(k) \equiv \text{out}_j^{(1)}(k) = f[\text{net}_j^{(1)}(k)], \quad j = \overline{1, J};$$

$$4) \text{net}_m^{(2)}(k) = \sum_{j=1}^J w_{jm}^{(2)}(k)x_j^{(2)}(k) + w_{0m}^{(2)}(k), \quad m = \overline{1, M};$$

$$5) y_m(k) \equiv \text{out}_m^{(2)}(k) = f[\text{net}_m^{(2)}(k)], \quad m = \overline{1, M}.$$

На *втором этапе* по известному желаемому выходу t_m («обучение с учителем») оценивают ошибки нейронов выходного и скрытого слоев (обратное распространение ошибки):

$$1) \delta_m(k) \equiv \delta_m^{(2)}(k) = \frac{df[\text{net}_m^{(2)}(k)]}{d \text{net}_m^{(2)}(k)} [t_m - y_m(k)], \quad m = \overline{1, M};$$

$$2) \delta_j^{(1)}(k) = \frac{df[\text{net}_j^{(1)}(k)]}{d \text{net}_j^{(1)}(k)} \sum_{m=1}^M w_{jm}^{(2)}(k)\delta_m(k), \quad j = \overline{1, J}.$$

После этого на *третьем этапе* производят настройку весов:

$$1) w_{ij}^{(1)}(k+1) = w_{ij}^{(1)}(k) + \Delta w_{ij}^{(1)}(k), \quad \Delta w_{ij}^{(1)}(k) = \eta x_i \delta_j^{(1)}(k);$$

$$2) w_{jm}^{(2)}(k+1) = w_{jm}^{(2)}(k) + \Delta w_{jm}^{(2)}(k), \quad \Delta w_{jm}^{(2)}(k) = \eta x_j^{(2)}(k) \delta_m(k).$$

Норму обучения следует принять $\eta \in (0, 1]$.

Затем по тому же входному сигналу x_i выполняется расчет нового выходного вектора $y_j(k+1)$ и далее аналогично вплоть до

достижения эпохи $k = K$, на которой суммарная среднеквадратичная ошибка не превысит некоторого порога $0 < \varepsilon \leq 1$:

$$E(k) = \sqrt{\sum_{j=1}^M [t_j - y_j(k)]^2} \leq \varepsilon.$$

Практическая часть

Пример выполнения работы. Выберем в качестве примера МНС архитектуру $3 - 3 - 4$ ($N = 3$, $J = 3$, $M = 4$). Пусть требуется обучить МНС на восстановление по входному вектору

$$\mathbf{x} = (1, 0, 3, -0, 1, 0, 9)$$

целевого вектора

$$\mathbf{t} = (0, 1, -0, 6, 0, 2, 0, 7)$$

с погрешностью не более $\varepsilon = 1 \cdot 10^{-3}$.

Исходные веса примем нулевыми:

$$w_{ij}^{(1)}(0) = 0, \quad i = \overline{0, N}, \quad j = \overline{1, J};$$

$$w_{jm}^{(2)}(0) = 0, \quad j = \overline{0, J}, \quad m = \overline{1, M}.$$

В табл. 6.1 приведены некоторые результаты обучения МНС методом ВР при значении параметра $\eta = 1$.

Таблица 6.1

Параметры НС на последовательных эпохах

Номер эпохи k	Выходной вектор \mathbf{y}	Суммарная ошибка $E(k)$
0	(0, 0, 0, 0)	$E(0) = 0,949$
1	(0,025, -0,149, 0,050, 0,173)	$E(1) = 0,714$
...
$K = 73$	(0,100, -0,600, 0,200, 0,699)	$E(73) = 9,816 \cdot 10^{-4}$

Варианты заданий

Таблица 6.2

Варианты МНС

№ варианта	Архитектура	x	10t	№ варианта	Архитектура	x	10t
1	1 – 2 – 1	(1, 2)	4	14	1 – 2 – 1	(1, 2)	-3
2	1 – 1 – 3	(1, -1)	(2, -3, 1)	15	1 – 1 – 3	(1, -3)	(1, 1, 1)
3	2 – 1 – 2	(1, 2, 1)	(2, 1)	16	2 – 1 – 2	(1, 2, 1)	(-1, -1)
4	1 – 2 – 1	(1, 3)	1	17	1 – 2 – 1	(1, 2)	3
5	1 – 1 – 3	(1, 2)	(-1, 0, 2)	18	1 – 1 – 3	(1, -1)	(-1, 2, 2)
6	2 – 1 – 2	(1, 1, -1)	(2, -1)	19	2 – 1 – 2	(1, 2, -1)	(2, -2)
7	1 – 2 – 1	(1, 4)	-2	20	1 – 2 – 1	(1, -3)	1
8	1 – 1 – 3	(1, -2)	(2, 1, 3)	21	1 – 1 – 3	(1, -1)	(-3, 2, 1)
9	2 – 1 – 2	(1, 2, 2)	(3, 1)	22	2 – 1 – 2	(1, 2, 3)	(1, 2)
10	1 – 2 – 1	(1, 3)	-4	23	1 – 2 – 1	(1, 3)	4
11	1 – 1 – 3	(1, -3)	(-3, 1, 1)	24	1 – 1 – 3	(1, -2)	(-1, 2, 3)
12	2 – 1 – 2	(1, 1, 2)	(2, 2)	25	2 – 1 – 2	(1, 2, 2)	(2, 3)
13	1 – 2 – 1	(1, -3)	-1	26	1 – 2 – 1	(1, -2)	3

Порядок защиты лабораторной работы. Для защиты лабораторной работы студент должен продемонстрировать программную реализацию НС с заданной в варианте архитектурой (табл. 6.2), результаты обучения сети со всеми промежуточными шагами; предоставить подготовленный отчет согласно указанным ниже требованиям и ответить на контрольные вопросы по теоретической и практической частям работы.

Требования к отчету. В отчете должны содержаться: титульный лист; цель работы; постановка задачи; график или таблица суммарной квадратичной ошибки в зависимости от эпохи обучения; целевые значения и реальный выход НС на каждой эпохе обучения; наборы синаптических коэффициентов (весов) на каждой эпохе обучения; выводы по результатам численного эксперимента.

Контрольные вопросы

1. Дайте определение МНС и объясните ее принципиальное отличие от однослоиной с точки зрения нелинейной классификации.
2. В чем заключается основная идея метода обратного распространения ошибки?
3. Сформулируйте теорему Колмогорова об аппроксимации.

Лабораторная работа № 7

Исследование рекуррентной нейронной сети Хопфилда на примере задачи распознавания образов

Цель работы — исследовать процедуры обучения и функционирования рекуррентной нейронной сети (РНС) Хопфилда в качестве устройства автоассоциативной памяти.

Теоретическая часть

Постановка задачи. Закодировать запоминаемые образы (табл. 7.1) в виде биполярных матриц-паттернов размерности $I \times J$ (рекомендуемое число пикселей $IJ \approx 20...40$). Произвести векторизацию матриц. Провести настройку весов РНС Хопфилда (рис. 7.1) согласно правилу ассоциативного обучения (Хебба). Задать функцию активации и реализовать алгоритм функционирования РНС Хопфилда в синхронном или асинхронном режиме. Протестировать РНС на запомненных эталонных образах. Проверить функционирование РНС Хопфилда на искаженных паттернах (изменены порядка 10 % пикселей).

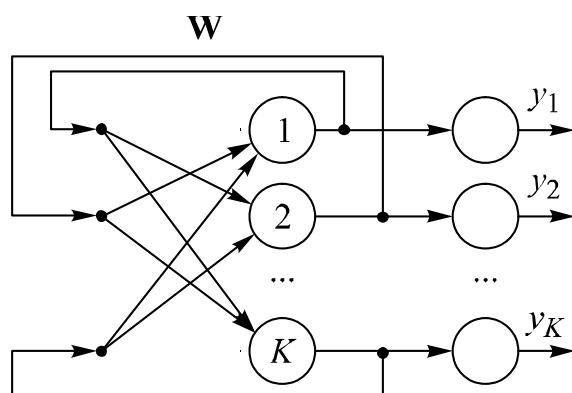


Рис. 7.1. Рекуррентная нейронная сеть Хопфилда

Рабочий режим. РНС Хопфилда является *автоассоциативной* памятью, которая в ответ на входное воздействие-сигнал

$$\mathbf{x} = (x_1, x_2, \dots, x_K), \quad x_k \in \{-1, 1\}, \quad k = 1, 2, \dots, K,$$

формирует отклик

$$\mathbf{y} = (y_1, y_2, \dots, y_K), \quad y_k \in \{-1, 1\}, \quad k = 1, 2, \dots, K,$$

структурно соответствующий прототипу.

В *синхронном режиме* каждая эпоха с номером $n = 1, 2, \dots$ включает в себя следующие вычисления:

$$\text{net}_k^{(n)} = \sum_{\substack{j=1 \\ (j \neq k)}}^K w_{jk} y_j^{(n-1)}, \quad y_k^{(n)} = f(\text{net}_k^{(n)}), \quad k = 1, 2, \dots, K. \quad (7.1)$$

Здесь функция активации каждого нейрона

$$f(\text{net}_k^{(n)}) = \begin{cases} 1, & \text{net}_k^{(n)} > 0, \\ f(\text{net}_k^{(n-1)}), & \text{net}_k^{(n)} = 0, \\ -1, & \text{net}_k^{(n)} < 0. \end{cases}$$

В *асинхронном режиме* вместо (7.1) имеем

$$\begin{aligned} \text{net}_k^{(n)} &= \sum_{j=1}^{k-1} w_{jk} y_j^{(n)} + \sum_{j=k+1}^K w_{jk} y_j^{(n-1)}, \\ y_k^{(n)} &= f(\text{net}_k^{(n)}), \quad k = 1, 2, \dots, K. \end{aligned} \quad (7.2)$$

На каждой эпохе вместо прямого порядка (7.2) можно реализовать любой другой, в том числе случайный, порядок обновления нейронов.

Инициализация. Для начала работы РНС Хопфилда необходимо задать начальные условия:

$$y_k^{(0)} = x_k, \quad k = 1, 2, \dots, K,$$

а также вычислить компоненты матрицы весов:

$$w_{jk} = \begin{cases} \sum_{l=1}^L x_j^{(l)} x_k^{(l)}, & j \neq k, \\ 0, & j = k, \end{cases} \quad (7.3)$$

где L — «емкость» ассоциативной памяти (количество запоминаемых образов); l — номера запоминаемых образов-паттернов.

Практическая часть

Пример выполнения работы. Пусть требуется запомнить три образа, представляющих собой графические изображения цифр «1», «2», «3». В качестве примера закодируем их в виде биполярных матриц-паттернов размерности 5×3 (рис. 7.2). Векторизуем матрицы по столбцам для получения рабочих векторов длины 15:

$$\mathbf{x}^{(1)} = (-1, 1, -1, -1, 1, 1, 1, 1, 1, -1, -1, -1, -1, 1),$$

$$\mathbf{x}^{(2)} = (1, -1, 1, 1, 1, 1, -1, 1, -1, 1, 1, 1, 1, -1, 1),$$

$$\mathbf{x}^{(3)} = (1, -1, 1, -1, 1, 1, -1, 1, -1, 1, 1, 1, 1, 1, 1).$$

«1»	-1	1	-1	«2»	1	1	1	«3»	1	1	1
	1	1	-1		-1	-1	1		-1	-1	1
	-1	1	-1		1	1	1		1	1	1
	-1	1	-1		1	-1	-1		-1	-1	1
	1	1	1		1	1	1		1	1	1

Рис. 7.2. Биполярный код образов

Настроим веса РНС Хопфилда, записав (7.3) в векторно-матричном виде:

$$\mathbf{W} = \left(\sum_{l=1}^3 \mathbf{X}^{(l)\top} \mathbf{X}^{(l)} \right)',$$

где штрихом обозначена операция обнуления главной диагонали.

В итоге получим:

$$\mathbf{W} = \begin{pmatrix} 0 & -3 & 3 & 1 & 1 & 1 & -3 & 1 & -3 & 1 & 3 & 3 & 3 & 3 & 1 & 1 \\ -3 & 0 & -3 & -1 & -1 & -1 & 3 & -1 & 3 & -1 & -3 & -3 & -3 & -3 & -1 & -1 \\ 3 & -3 & 0 & 1 & 1 & 1 & -3 & 1 & -3 & 1 & 3 & 3 & 3 & 3 & 1 & 1 \\ 1 & -1 & 1 & 0 & -1 & -1 & -1 & -1 & -1 & -1 & 1 & 1 & 1 & 1 & -1 & -1 \\ 1 & -1 & 1 & -1 & 0 & 3 & -1 & 3 & -1 & 3 & 1 & 1 & 1 & 1 & -1 & 3 \\ 1 & -1 & 1 & -1 & 3 & 0 & -1 & 3 & -1 & 3 & 1 & 1 & 1 & 1 & -1 & 3 \\ -3 & 3 & -3 & -1 & -1 & -1 & 0 & -1 & 3 & -1 & -3 & -3 & -3 & -3 & -1 & -1 \\ 1 & -1 & 1 & -1 & 3 & 3 & -1 & 0 & -1 & 3 & 1 & 1 & 1 & 1 & -1 & 3 \\ -3 & 3 & -3 & -1 & -1 & -1 & 3 & -1 & 0 & -1 & -3 & -3 & -3 & -3 & -1 & -1 \\ 1 & -1 & 1 & -1 & 3 & 3 & -1 & 3 & -1 & 0 & 1 & 1 & 1 & 1 & -1 & 3 \\ 3 & -3 & 3 & 1 & 1 & 1 & -3 & 1 & -3 & 1 & 0 & 3 & 3 & 3 & 1 & 1 \\ 3 & -3 & 3 & 1 & 1 & 1 & -3 & 1 & -3 & 1 & 3 & 0 & 3 & 3 & 1 & 1 \\ 3 & -3 & 3 & 1 & 1 & 1 & -3 & 1 & -3 & 1 & 3 & 3 & 0 & 1 & 1 & 1 \\ 1 & -1 & 1 & -1 & -1 & -1 & -1 & -1 & -1 & -1 & 1 & 1 & 1 & 1 & 0 & -1 \\ 1 & -1 & 1 & -1 & 3 & 3 & -1 & 3 & -1 & 3 & 1 & 1 & 1 & 1 & -1 & 0 \end{pmatrix}.$$

Для тестирования сети подадим поочередно все три рабочих вектора на вход. Можно убедиться, что в синхронном режиме, если записать (7.1) в векторно-матричном виде, результат будет следующий:

$$f(\mathbf{x}^{(l)} \mathbf{W}) = \mathbf{x}^{(l)}, \quad l = 1, 2, 3.$$

Попробуем исказить, например, входной образ $\mathbf{x}^{(1)}$, инвертировав биты 2 и 3:

$$\tilde{\mathbf{x}}^{(1)} = (-1, -1, 1, -1, 1, 1, 1, 1, 1, -1, -1, -1, 1).$$

Результатом работы РНС Хопфилда будет восстановление исходного эталона:

$$f(\tilde{\mathbf{x}}^{(1)} \mathbf{W}) = \mathbf{x}^{(1)}.$$

Варианты заданий

Таблица 7.1

Запоминаемые образцы и режимы работы РНС Хопфилда

№ варианта	Режим работы РНС Хопфилда	Запоминаемые образы
1	Синхронный	0 1 8
2	Синхронный	A I F
3	Асинхронный	1 3 7
4	Асинхронный	3 4 5
5	Синхронный	G H I
6	Синхронный	6 7 4
7	Асинхронный	1 3 5
8	Асинхронный	J K L
9	Синхронный	2 4 6
10	Синхронный	0 6 1
11	Асинхронный	S T U
12	Асинхронный	3 5 7
13	Синхронный	2 4 8
14	Синхронный	X Y Z
15	Асинхронный	0 1 9
16	Асинхронный	I V X

Окончание табл. 7.1

№ варианта	Режим работы РНС Хопфилда	Запоминаемые образы
17	Синхронный	B C I
18	Синхронный	D E X
19	Асинхронный	G H L
20	Асинхронный	0 2 7
21	Синхронный	F H J
22	Синхронный	1 4 7
23	Асинхронный	N O P
24	Асинхронный	S V Z
25	Синхронный	1 3 5

Порядок защиты лабораторной работы. Для защиты лабораторной работы студент должен продемонстрировать программную реализацию НС, запоминающей заданные в варианте образцы, результаты обучения сети; предоставить подготовленный отчет согласно указанным ниже требованиям и ответить на контрольные вопросы по теоретической и практической частям работы.

Требования к отчету. В отчете должны содержаться: титульный лист; цель работы; постановка задачи; закодированные эталонные образы (паттерны); рассчитанная матрица весов обратных связей; результаты тестирования РНС для эталонных паттернов; результаты работы РНС при искаженных паттернах; выводы по результатам численного эксперимента.

Контрольные вопросы

1. Как происходит обучение ассоциативного типа (без учителя)? Сформулируйте правило Хебба.
2. Дайте определение ассоциативной памяти.
3. Расскажите о НС Хопфилда, алгоритмах ее обучения и функционировании.

Лабораторная работа № 8

Исследование рекуррентной нейронной сети Коско (ВАМ) на примере задачи распознавания образов

Цель работы — исследовать процедуру обучения и функционирования РНС Коско как модели двунаправленной гетероассоциативной памяти (англ. Bidirectional Associative Memory — ВАМ).

Теоретическая часть

Постановка задачи. Закодировать запоминаемые образы (варианты см. в табл. 7.1) в виде биполярных матриц-паттернов размерности $I \times J$ (рекомендуемое число пикселей $IJ \approx 20...40$). Произвести векторизацию матриц. Установить каждому образу его пару-ассоциацию как биполярный вектор длины 3. Провести настройку весов РНС Коско (рис. 8.1) согласно правилу ассоциативного обучения (Хебба). Задать функцию активации и реализовать алгоритм функционирования РНС Коско в двунаправленном режиме. Протестировать РНС на запомненных эталонных образах в прямом и обратном режимах. Проверить функционирование РНС Коско в прямом режиме на искаженных паттернах (изменены порядка 10 % пикселей).

Рабочий режим. РНС Коско является гетероассоциативной памятью, которая в ответ на входное воздействие-сигнал

$$\mathbf{s} = (s_1, s_2, \dots, s_m), s_i \in \{-1, 1\} \quad (i = \overline{1, m})$$

формирует отклик

$$\mathbf{t} = (t_1, t_2, \dots, t_n), t_j \in \{-1, 1\} \quad (j = \overline{1, n})$$




Рис. 8.1. РНС Коско (ВАМ)

и обратно, по сигналу t в качестве прообраза восстанавливает образ s (в общем случае $m \neq n$).

В рабочем режиме производятся следующие вычисления:

1) инициализация выхода нейронов первого слоя:

$$y_i(0) = s_i \quad (i = \overline{1, m});$$

2) расчет сигналов комбинированных входов нейронов второго слоя:

$$\text{net}_j = \sum_{i=1}^m s_i w_{ij} \quad (j = \overline{1, n});$$

3) расчет выходов нейронов второго слоя:

$$t_j = f(\text{net}_j) \quad (j = \overline{1, n});$$

4) расчет сигналов комбинированных входов нейронов первого слоя:

$$\text{net}_i = \sum_{j=1}^n t_j w_{ji} \quad (i = \overline{1, m});$$

5) расчет выходов нейронов первого слоя:

$$s_i = f(\text{net}_i) \quad (i = \overline{1, m});$$

6) повторение шагов 2–5 до стабилизации обоих выходов РНС Коско.

Порядок вычислений может быть другим, т. е. начинаться с активации нейронов второго слоя:

$$y_j(0) = t_j \quad (j = \overline{1, n}),$$

после чего выполняют сначала шаги 4, 5, а затем — 2, 3.

Функция активации каждого нейрона на k -й эпохе имеет вид

$$f(\text{net}_i^{(k)}) = \begin{cases} 1, & \text{net}_i^{(k)} > 0, \\ f(\text{net}_i^{(k-1)}), & \text{net}_i^{(k)} = 0, \\ -1, & \text{net}_i^{(k)} < 0. \end{cases}$$

Инициализация. Для начала работы РНС Коско необходимо по правилу Хебба вычислить компоненты матрицы весов:

$$w_{ij} = \sum_{l=1}^L s_i^{(l)} t_j^{(l)} \quad (i = \overline{1, m}, j = \overline{1, n}), \quad (8.1)$$

где L — «емкость» гетероассоциативной памяти (количество запоминаемых пар образов); l — номера запоминаемых пар образов.

Практическая часть

Пример выполнения работы. Пусть требуется запомнить три образа, представляющих собой графические изображения цифр «1», «2», «3». В качестве примера закодируем их в виде биполярных матриц-паттернов размерности 5×3 (см. рис. 7.2). Векторизуем матрицы по столбцам для получения рабочих векторов длины $m = 15$:

$$\begin{aligned}\mathbf{s}^{(1)} &= (-1, 1, -1, -1, 1, 1, 1, 1, 1, 1, -1, -1, -1, -1, 1); \\ \mathbf{s}^{(2)} &= (1, -1, 1, 1, 1, 1, -1, 1, -1, 1, 1, 1, 1, -1, 1); \\ \mathbf{s}^{(3)} &= (1, -1, 1, -1, 1, 1, -1, 1, -1, 1, 1, 1, 1, 1, 1).\end{aligned}$$

В качестве пар-ассоциаций возьмем биполярные векторы размерности $n = 3$:

$$\begin{aligned}\mathbf{t}^{(1)} &= (-1, -1, 1); \\ \mathbf{t}^{(2)} &= (-1, 1, -1); \\ \mathbf{t}^{(3)} &= (-1, 1, 1).\end{aligned}$$

Настроим веса РНС Коско, записав (8.1) в векторно-матричном виде:

$$\mathbf{W} = \sum_{l=1}^3 \mathbf{s}^{(l)\top} \mathbf{t}^{(l)}.$$

В итоге получим

$$\mathbf{W} = \begin{pmatrix} -1 & 1 & -1 & 1 & -3 & -3 & 1 & -3 & 1 & -3 & -1 & -1 & -1 & 1 & -3 \\ 3 & -3 & 3 & 1 & 1 & 1 & -3 & 1 & -3 & 1 & 3 & 3 & 3 & 1 & 1 \\ -1 & 1 & -1 & -3 & 1 & 1 & 1 & 1 & 1 & 1 & -1 & -1 & -1 & 1 & 1 \end{pmatrix}^\top.$$

Для тестирования сети активируем поочередно всеми тремя образами $\mathbf{s}^{(l)}$ ее первый слой и выполним шаги 2, 3 рабочего режима. В итоге на выходе нейронов второго слоя получим соответствующие пары-ассоциации $\mathbf{t}^{(l)}$. Аналогично при активации нейро-

нов второго слоя поочередно всеми тремя образами $t^{(l)}$ и выполнении шагов 4, 5 рабочего режима, получим на выходе нейронов первого слоя соответствующие пары $s^{(l)}$.

Попробуем исказить, например, входной образ $s^{(l)}$, инвертировав бит 4:

$$\tilde{s}^{(1)} = (-1, 1, -1, 1, 1, 1, 1, 1, 1, -1, -1, -1, -1, 1).$$

Результатом работы РНС Коско после шагов 2, 3 будет восстановление на выходе второго слоя исходного парного образа $\tilde{t}^{(1)} = (-1, -1, 1)$. Реализуя далее шаги 4, 5 рабочего режима, на выходе нейронов первого слоя восстановится неискаженный образ:

$$s^{(1)} = (-1, 1, -1, -1, 1, 1, 1, 1, 1, -1, -1, -1, -1, 1).$$

Аналогичная ситуация будет иметь место при внесении небольших искажений в любой из векторов $s^{(l)}, t^{(l)}$ ($l=1, 2, 3$).

Варианты заданий

Варианты заданий представлены в табл. 7.1.

Порядок защиты лабораторной работы. Для защиты лабораторной работы студент должен продемонстрировать программную реализацию НС, запоминающей заданные в варианте образцы, результаты обучения сети; предоставить подготовленный отчет согласно указанным ниже требованиям и ответить на контрольные вопросы по теоретической и практической частям работы.

Требования к отчету. В отчете должны содержаться: титульный лист; цель работы; постановка задачи; закодированные эталонные образы (паттерны) и их пары-ассоциации; рассчитанная матрица весов; результаты тестирования РНС Коско для эталонных паттернов в прямом и обратном направлении; результаты работы РНС Коско при искаженных паттернах; выводы по результатам численного эксперимента.

Контрольные вопросы

1. Как происходит обучение ассоциативного типа (без учителя)? Сформулируйте правило Хебба.

2. Дайте определение ассоциативной памяти.

3. Расскажите о НС Коско (ВАМ), алгоритмах ее обучения и функционировании.

Лабораторная работа № 9

Алгоритмы кластерного анализа данных

Цель работы — исследовать применение основных алгоритмов кластерного анализа, включая их модификации, на примере различных типов данных.

Теоретическая часть

Постановка задачи. Выполнить разбиение предложенных данных с помощью указанного в варианте (табл. 9.1) алгоритма с использованием соответствующих метрик.

Кластерный анализ — процедура, заключающаяся в сборе данных, содержащих информацию о выборке объектов, и последующем упорядочивании объектов в сравнительно однородные группы на основе какого-либо признака(ов). Формально: пусть X — множество объектов, Y — множество кластеров. Задана функция расстояния между объектами $\rho(x, x')$. Имеется конечная обучающая выборка объектов $X^m = \{x_1, \dots, x_m\} \subset X$. Требуется разбить выборку на непересекающиеся подмножества, называемые кластерами, так, чтобы каждый кластер состоял из объектов, близких по метрике ρ , а объекты разных кластеров существенно отличались. При этом каждому объекту $x_i \in X^m$ приписывается номер кластера y_i . *Алгоритм кластеризации* — это функция $\phi: X \rightarrow Y$, которая любому объекту $x \in X$ ставит в соответствие номер кластера $y \in Y$. Множество Y в некоторых случаях известно заранее, однако чаще ставится задача определить оптимальное число кластеров с точки зрения того или иного критерия качества кластеризации.

Существует множество методов кластерного анализа, наиболее известные из них:

- вероятностные алгоритмы (k -средних);

- подходы на основе применения искусственного интеллекта (НС Кохонена);
- теоретико-графовый подход и др.

В алгоритме *k*-средних (*k*-means) минимизируется суммарное квадратичное отклонение точек кластеров от центров этих кластеров:

$$S = \sum_{i=1}^k \sum_{x_j \in Y_i} (x_j - \mu_i)^2,$$

где k — количество кластеров (задано заранее); Y_i — полученные кластеры, $i=1, \dots, k$; μ_i — центры масс $x_j \in Y_i$.

Суть алгоритма заключается в следующем: на каждой итерации перевычисляется центр масс для каждого кластера, полученного на предыдущем шаге, затем кластеризуемые точки $x_j \in R^d$ разбиваются на кластеры вновь в соответствии с тем, какой из новых центров оказался ближе по выбранной метрике. Алгоритм завершается, когда на l -й итерации не изменяется центр масс кластеров. Это происходит за конечное число итераций, так как количество возможных разбиений конечного множества конечно, и на каждом шаге суммарное квадратичное отклонение S не увеличивается, поэтому зацикливание невозможно.

НС Кохонена — класс НС, основным элементом которых является слой Кохонена, состоящий из k адаптивных линейных сумматоров. Они имеют одинаковое число входов m и получают на свои входы вектор входных сигналов $\mathbf{x} = (x_1, \dots, x_m)$. На выходе j -го линейного элемента имеем сигнал

$$y_j = w_{j0} + \sum_{i=1}^m w_{ji} x_i,$$

где j — номер нейрона; w_{j0} — пороговый коэффициент; i — номер входа; w_{ji} — весовой коэффициент i -го входа j -го нейрона.

Выходные сигналы слоя Кохонена обрабатываются по правилу «победитель получает всё»: наибольший сигнал превращается в единичный, остальные обращаются в нуль. Таким образом, применительно к задаче кластеризации каждому j -му нейрону ставится в соответствие точки-центры кластеров, для входного вектора $\mathbf{x} = (x_1, \dots, x_m)$ вычисляются расстояния $r_j(\mathbf{x})$, и тот нейрон, до которого это расстояние минимально, выдает единицу, остальные — нуль.

Практическая часть

Пример выполнения работы. Рассмотрим пример выполнения кластеризации данных на примере разбивки на кластере координатных точек на форме приложения по методу k -средних. Пусть пользователь ввел семь координатных точек:

$$x_1 = (143, 213); \quad x_2 = (180, 220); \quad x_3 = (183, 249); \\ x_4 = (271, 253); \quad x_5 = (226, 253); \quad x_6 = (315, 275); \quad x_7 = (266, 297),$$

а также задал два кластера точками

$$Y_1 = (159, 238); \quad Y_2 = (270, 278)$$

(рис. 9.1, где точками обозначены исходные координатные точки, а квадратами — начальные центры кластеров). Теперь в цикле по всем исходным точкам нужно рассчитать расстояние ρ по заданной метрике (рассмотрим обычное, евклидово, расстояние) от каждой точки до центра каждого из заданных кластеров и отнести точку к тому или иному кластеру из соображений минимальности расстояния до центра кластера.

Получаем следующие значения:

$$\rho_{11} = 29,68; \quad \rho_{12} = 142,67; \quad \rho_{21} = 27,66; \quad \rho_{22} = 107,07; \\ \rho_{31} = 26,40; \quad \rho_{32} = 91,71; \quad \rho_{41} = 113,0; \quad \rho_{42} = 25,02; \quad \rho_{51} = 68,66; \\ \rho_{52} = 50,61; \quad \rho_{61} = 160,33; \quad \rho_{62} = 45,10; \quad \rho_{71} = 122,19; \quad \rho_{72} = 19,42.$$

Здесь ρ_{ij} — расстояние от i -й точки до центра j -го кластера. Таким образом, к первому кластеру будут отнесены точки $Y_1 \in \{x_1, x_2, x_3\}$, а ко второму $Y_2 \in \{x_4, x_5, x_6, x_7\}$.

На следующем шаге алгоритма перерассчитываются новые центры кластеров (как центры масс точек, отнесенных к j -му кластеру):

$$Y'_1 = (168,67; 227,34); \quad Y'_2 = (269,5; 269,5).$$

После чего процедура расчета расстояний ρ_{ij} до новых центров кластеров и отнесения к тому или иному кластеру повторяется до тех пор, пока на очередном шаге алгоритма больше не произойдет изменений центров кластеров относительно предыдущего шага:

$$Y_j^{l+1} = Y_j^l, \quad j = 1, \dots, k.$$

Тогда работу алгоритма можно считать законченной. Пример показан на рис. 9.2.

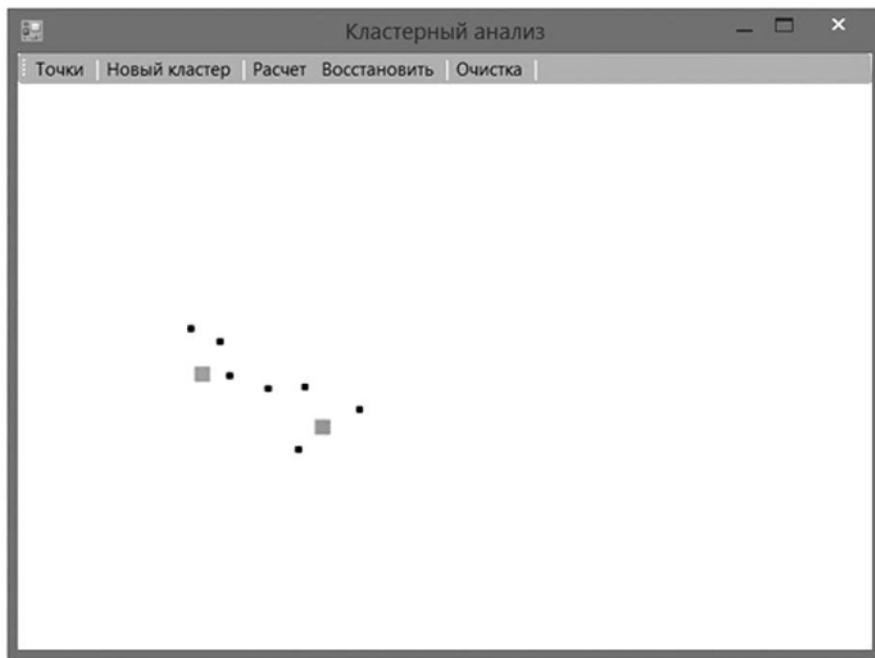


Рис. 9.1. Пример работы программы: введены исходные точки и начальные центры кластеров

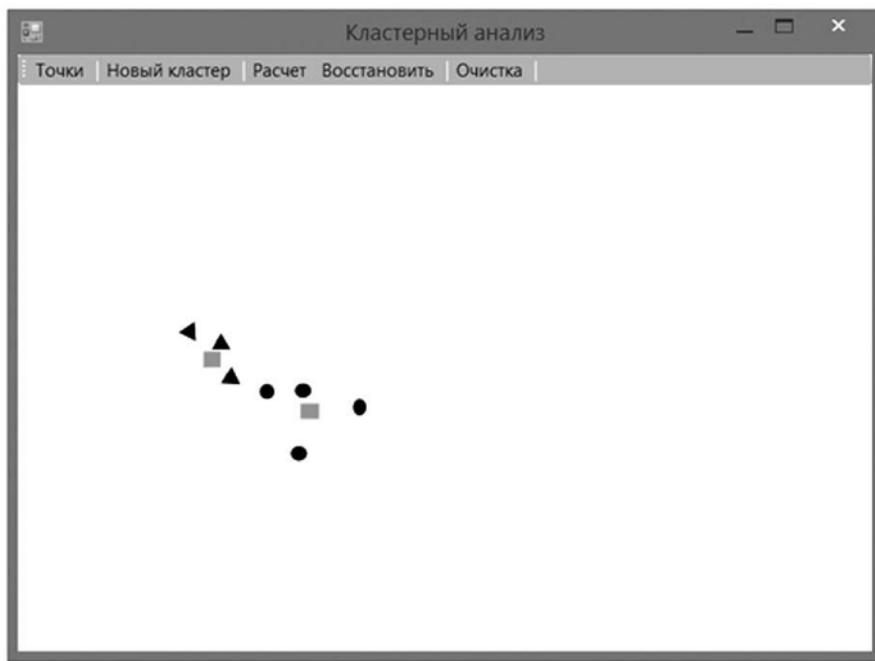


Рис. 9.2. Пример работы программы: результат разбиения точек на кластеры

Варианты заданий

Выполнить разбиение предложенных в табл. 9.1 данных на кластеры с помощью указанного алгоритма (с обеими предложенными в таблице метриками) согласно варианту. При этом:

- в *нечетных вариантах* задания должен быть предусмотрен пользовательский GUI для ввода данных (координатных точек на форме приложения) и вывода результата кластеризации; результат кластеризации должен отображаться с цветовым кодированием по принадлежности к кластеру; приветствуется пошаговое отображение результатов работы алгоритма;
- в *четных вариантах* задания приложение может быть выполнено как консольное с выводом в консоль или выходной файл; исходные объекты берутся с портала Правительства Москвы (<http://data.mos.ru/>) соответственно варианту. При кластеризации данных из коллекций портала должны использоваться только указанные в задании поля (координаты (X, Y) или количество мест), а остальные поля (название округа и т. п.) необходимо использовать только при проверке результатов кластеризации.

Таблица 9.1

Варианты заданий

№ варианта	Алгоритм	Исходные кластеризуемые данные	ρ
1	k -средних	Координатные точки на форме приложения	Евклида, Чебышева
2	НС Кохонена	Выборка колледжей г. Москвы. Координаты местоположения (X, Y)	Принадлежность округу Москвы (евклидово расстояние до координат (X_0, Y_0) центра округа)
3	k -средних	Координатные точки на форме приложения	Евклида, Манхэттен
4	НС Кохонена	Выборка лицеев г. Москвы. Координаты местоположения (X, Y)	Принадлежность округу Москвы (евклидово расстояние до координат (X_0, Y_0) центра округа)
5	k -средних	Координатные точки на форме приложения	Манхэттен, Чебышева

Продолжение табл. 9.1

№ варианта	Алгоритм	Исходные кластеризуемые данные	ρ
6	k -средних	Выборка велопарковок г. Москвы. Координаты местоположения (X, Y)	Принадлежность округу Москвы (евклидово расстояние до координат (X_0, Y_0) центра округа)
7	k -медиан	Координатные точки на форме приложения	Евклида, Чебышева
8	НС Кохонена	Выборка платных парковок г. Москвы. Вместительность (машин), достаточный размер выборки $N = 200$ объектов	Вместительность, количество машин (кластеры предложить самостоятельно)
9	k -медиан	Координатные точки на форме приложения	Евклида, Манхэттен
10	НС Кохонена	Выборка кинотеатров г. Москвы. Координаты местоположения (X, Y)	Принадлежность округу Москвы (евклидово расстояние до координат (X_0, Y_0) центра округа)
11	k -медиан	Координатные точки на форме приложения	Манхэттен, Чебышева
12	НС Кохонена	Выборка взрослых больниц г. Москвы. Координаты местоположения (X, Y) или количество коек для больных	Принадлежность округу Москвы (евклидово расстояние до координат (X_0, Y_0) центра округа) или количество коек для больных
13	k -средних	Координатные точки на форме приложения	Евклида, Чебышева
14	НС Кохонена	Выборка взрослых поликлиник г. Москвы. Координаты местоположения (X, Y)	Принадлежность округу Москвы (евклидово расстояние до координат (X_0, Y_0) центра округа)
15	k -средних	Координатные точки на форме приложения	Евклида, Манхэттен

Окончание табл. 9.1

№ варианта	Алгоритм	Исходные кластеризуемые данные	ρ
16	НС Кохонена	Выборка библиотек г. Москвы. Координаты местоположения (X, Y), достаточный размер выборки $N = 200$ объектов	Принадлежность округу Москвы (евклидово расстояние до координат (X_0, Y_0) центра округа)
17	k -средних	Координатные точки на форме приложения	Манхэттен, Чебышева
18	НС Кохонена	Выборка музеев г. Москвы. Занимаемая музеем площадь (LandArea)	Занимаемая музеем площадь (LandArea)
19	НС Кохонена	Координатные точки на форме приложения	Евклида, Чебышева
20	НС Кохонена	Выборка театров г. Москвы. Вместительность, мест в залах	Вместительность, количество мест в залах (кластеры предложить самостоятельно)
21	НС Кохонена	Координатные точки на форме приложения	Евклида, Манхэттен
22	НС Кохонена	Выборка детских садов г. Москвы. Координаты местоположения (X, Y), выбрать случайным образом (не подряд) $N = 200$ объектов	Принадлежность округу Москвы (евклидово расстояние до координат (X_0, Y_0) центра округа)
23	НС Кохонена	Координатные точки на форме приложения	Манхэттен, Чебышева
24	НС Кохонена	Выборка детских садов г. Москвы. Координаты местоположения (X, Y), выбрать случайным образом (не подряд) $N = 200$ объектов	Принадлежность округу Москвы (евклидово расстояние до координат (X_0, Y_0) центра округа)
25	k -средних	Координатные точки на форме приложения	Евклида, Манхэттен

Порядок защиты лабораторной работы. Для защиты лабораторной работы студент должен продемонстрировать программную реализацию НС или алгоритма кластеризации, в зависимости от варианта; предоставить подготовленный отчет согласно указанным ниже требованиям и ответить на контрольные вопросы по теоретической и практической частям работы.

Требования к отчету. В отчете должны содержаться: титульный лист; цель работы; постановка задачи; примеры работы программы; результат решения поставленной задачи (итог работы программы), а также выводы по результатам численного эксперимента.

Контрольные вопросы

1. Дайте классификацию алгоритмов кластерного анализа данных.
2. Сформулируйте основные шаги алгоритма функционирования НС Кохонена.
3. Сформулируйте основные шаги алгоритма k -средних.
4. Перечислите основные достоинства и недостатки алгоритма k -средних.

Литература

Волчихин В.И., Иванов А.И., Назаров И.Г., Фунтиков В.А., Язов Ю.К. Нейросетевая защита персональных биометрических данных. М.: Радиотехника, 2012. 160 с.

Каллан Р. Основные концепции нейронных сетей. М.: Вильямс, 2003. 288 с.

Тадеусевич Р., Боровик Б., Гончаж Т., Леппер Б. Элементарное введение в технологию нейронных сетей с примерами программ. М.: Горячая линия — Телеком, 2011. 408 с.

Шелухин О.И., Сакалема Д.Ж., Филинова А.С. Обнаружение вторжений в компьютерные сети (сетевые аномалии). М.: Горячая линия — Телеком, 2013. 220 с.

Содержание

Предисловие	3
Лабораторная работа № 1. Исследование однослойных нейронных сетей на примере моделирования булевых выражений	6
Лабораторная работа № 2. Применение однослойной нейронной сети для решения задач регрессии экспериментальных данных	13
Лабораторная работа № 3. Применение однослойной нейронной сети с линейной функцией активации для прогнозирования временных рядов	18
Лабораторная работа № 4. Исследование нейронных сетей с радиальными базисными функциями (RBF) на примере моделирования булевых выражений	24
Лабораторная работа № 5. Исследование аппроксимативных свойств нейронных сетей с радиальными базисными функциями (RBF)	29
Лабораторная работа № 6. Изучение алгоритма обратного распространения ошибки (метод Back Propagation).....	33
Лабораторная работа № 7. Исследование рекуррентной нейронной сети Хопфилда на примере задачи распознавания образов.....	38
Лабораторная работа № 8. Исследование рекуррентной нейронной сети Коско (ВАМ) на примере задачи распознавания образов	43
Лабораторная работа № 9. Алгоритмы кластерного анализа данных...	47
Литература.....	54

Учебное издание

**Басараб Михаил Алексеевич
Коннова Наталья Сергеевна**

**Интеллектуальные технологии
на основе искусственных нейронных сетей**

Редактор *Е.Д. Нефедова*

Художник *Э.Ш. Мурадова*

Корректор *Н.В. Савельева*

Компьютерная графика *О.В. Левашовой*

Компьютерная верстка *Н.Ф. Бердавцевой*

Оригинал-макет подготовлен
в Издательстве МГТУ им. Н.Э. Баумана.

В оформлении использованы шрифты
Студии Артемия Лебедева.

Подписано в печать 11.05.2017. Формат 60×90/16.

Усл. печ. л. 3,5. Тираж 100 экз. Изд. № 225-2017.

Заказ

Издательство МГТУ им. Н.Э. Баумана.
105005, Москва, 2-я Бауманская ул., д. 5, стр. 1.
press@bmstu.ru
www.baumanpress.ru

Отпечатано в типографии МГТУ им. Н.Э. Баумана.
105005, Москва, 2-я Бауманская ул., д. 5, стр. 1.
baumanprint@gmail.com